Нейросетевая аппроксимация широкодиапазонного уравнения состояния вещества с учетом термодинамических ограничений

Выполнили: «Филиал МГУ в городе Сарове»

Елагин Матвей - капитан
Селивохин Ярослав
Королёва Ульяна
Володченко Александра
Деревянкин Кирилл





Цель

Разработать вычислительно эффективную нейросетевую модель широкодиапазонного уравнения состояния алюминия, приближающую табличные зависимости давления P и удельной внутренней энергии E от плотности ρ и температуры T с контролем физической согласованности.

Задачи

01

Проанализировать данные (EDA)

02

Разработать baseline

03

Разработать и обучить Vanilla

04

Исследовать физические ограничения

05

Разработать и обучить PINN

06

Сравнить модели

07

Реализовать программный интерфейс

Математическая постановка

Данные:

Вход: плотность ρ и температура T.
Выход: давление P и удельная внутренняя энергия E.

Критерий качества

Точность P и E на общем test-наборе. Отдельно: ошибки производных и доли нарушений ограничений.

$$f\theta(\rho, T) = [P\theta(\rho, T), E\theta(\rho, T)]$$

Табличная аппроксимация УРС алюминия в 20 областях состояния.

Теоретическая база

Точность и физика:

Обычная регрессия минимизирует ошибку по P и E. Этого недостаточно для соблюдения ограничений на производные.

Проверки:

$\partial P/\partial \rho > 0$; $\partial E/\partial T \geq 0$. Дополнительно проверяется знак $\partial P/\partial T$. В исходных таблицах есть локальные нарушения и плато.

Данные и обработка

Объём и диапазоны

20 областей, 1 130 053 точки.
ρ: 10^{-3}-10^{4} г/см³; T: 10^{-1}-10^{7} K.

Проверки при чтении

Проверяются единицы, NaN, дубликаты (ρ,T), положительность ρ и T, размеры и границы областей.

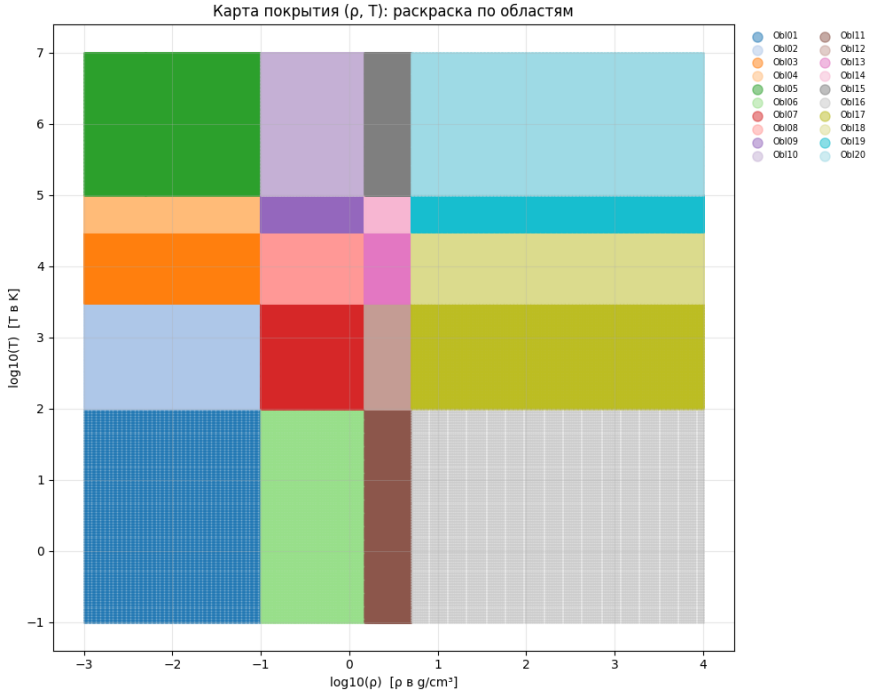
Сетки и балансировка

12 log×log, 4 lin×log,
3 log×lin, 1 lin×lin. В обучении используются веса точек по областям.

Особенности энергии

19,4% значений E отрицательны. Для энергии применяется $\operatorname{asinh}(E/E_0)$, а не обычный логарифм.

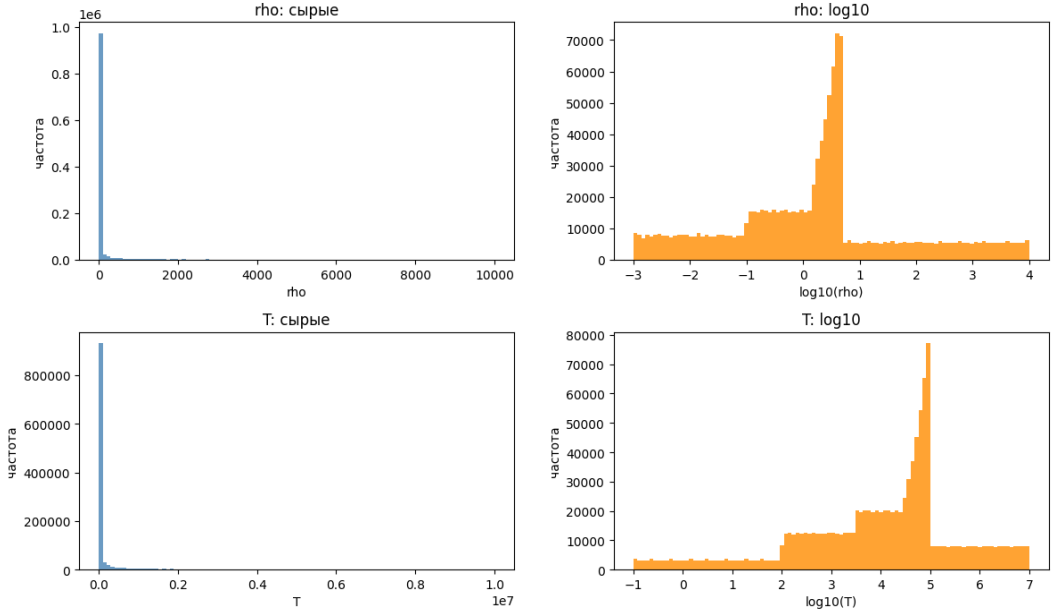
EDA: покрытие и особенности таблиц



Неравномерная плотность точек

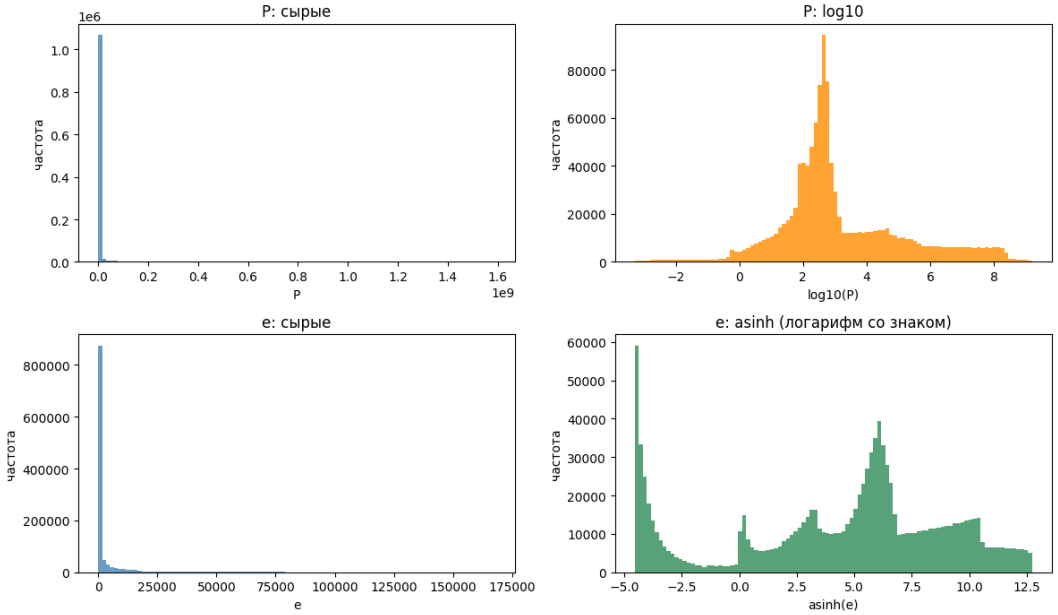
В интервале, занимающем **7,5%** логарифмической шкалы плотности, сосредоточено **34,5%** точек. При T ≈ 142 K в Obl02 обнаружен скачок P и E. Это влияет на ошибки интерполяции и физические проверки.

EDA: масштаб входных признаков



После $\log_{10}$ распределения ρ и T становятся менее скошенными. Далее применяется MinMaxScaler по train.

EDA: преобразования давления и энергии



Для положительного P используется $\log_{10}$. Преобразование $\text{asinh}(E/E_0)$ сохраняет отрицательные значения энергии.

Асимметрия и эксцесс

Величина	n	Skew	Kurtosis	Std	В нижнем 1% шкалы, %
ρ (сырое)	1 130 053	5,185	28,917	1 209,581	86,074
$\log_{10}(\rho)$	1 130 053	0,229	−0,021	1,560	0,751
T (сырое)	1 130 053	4,555	22,015	1 338 240,098	82,376
$\log_{10}(T)$	1 130 053	−0,799	0,539	1,665	0,328
P (сырое)	1 130 053	14,145	251,203	59 576 612,912	94,344
$\log_{10}(P)$	1 130 053	0,675	0,811	1,969	0,055
e (сырое)	1 130 053	4,994	27,328	19 746,675	77,392
e (z-score)	1 130 053	4,994	27,328	1,000	77,392
asinh(e)	1 130 053	−0,473	−0,743	4,793	5,226
$\log_{10}(e-e_min+1)$	1 130 053	0,595	−0,113	1,081	0,197

Нормировка и разбиение

Входные признаки

$\log_{10}\rho$, $\log_{10}T$; затем MinMaxScaler в диапазон [-1, 1].

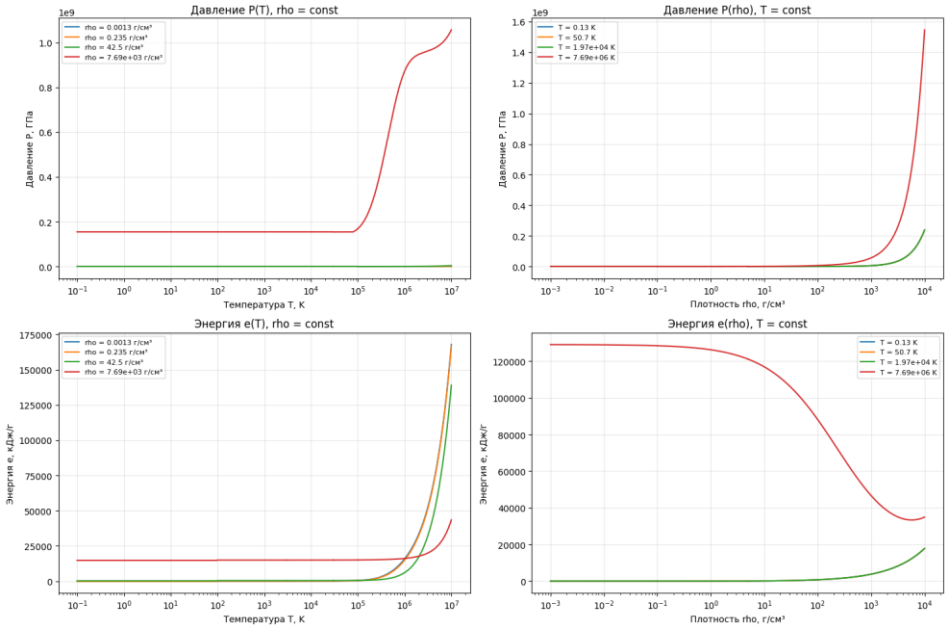
Целевые величины

$\log_{10}P$ и asinh(E); затем RobustScaler.

Train: узлы прореженной сетки. Остальные: val/test = 20/80, seed = 0.

Выборка	Количество точек
Train	286 521
Validation	168 706
Test	674 826

Сечения табличного УРС

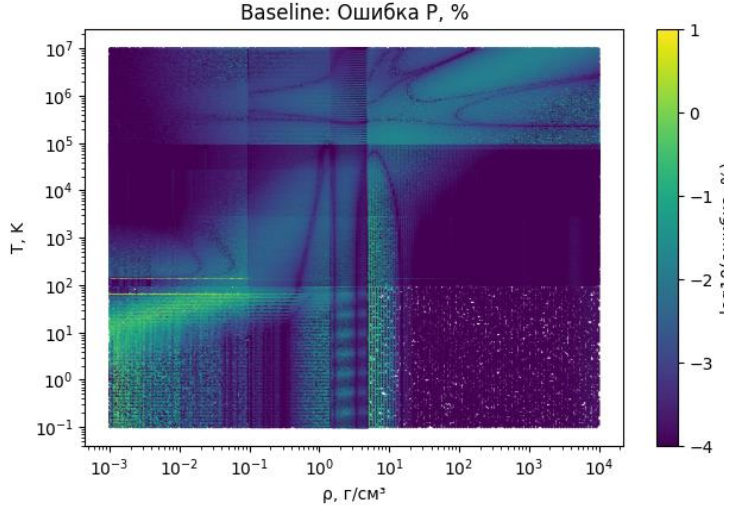


Сечения при четырёх фиксированных плотностях и температурах; интерполяция внутри областей учитывает тип сетки.

Baseline: билинейная интерполяция

Проверка точности:

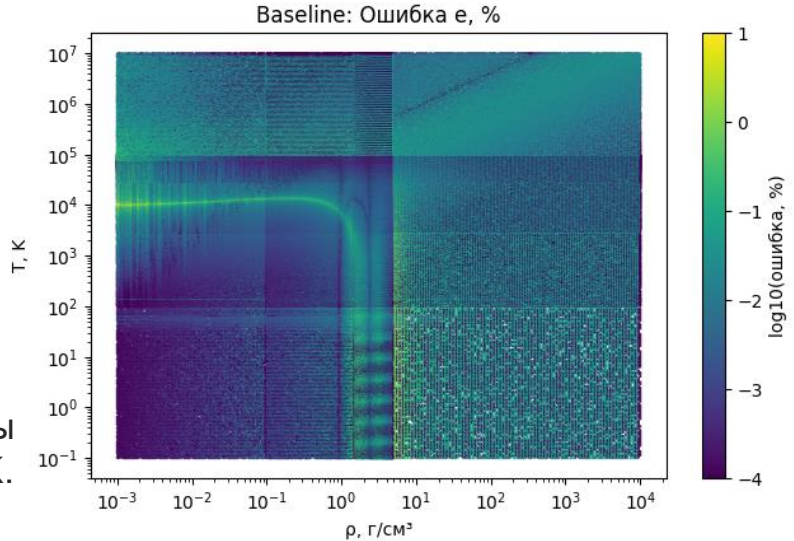
Интерполятор построен по train-узлам.
Test: 674 826 точек из 20 областей.



Наибольшие ошибки давления связаны со скачком таблицы около T ≈ 142 K.

Метрики:

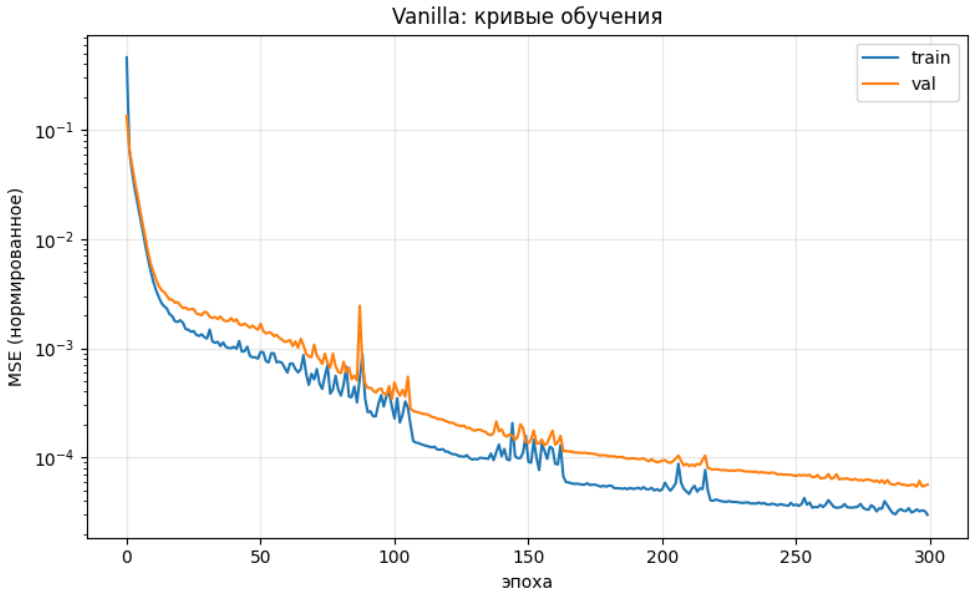
Медиана ошибки P: 0,000453%.
Медиана ошибки E: 0,00396%.
Максимум ошибки P: 20,39%.
Максимум ошибки E: 13,62 %.



Vanilla: обучение по табличным данным

MLP:

- 2 входа
- 4 скрытых слоя по 256 нейронов
- 2 выхода



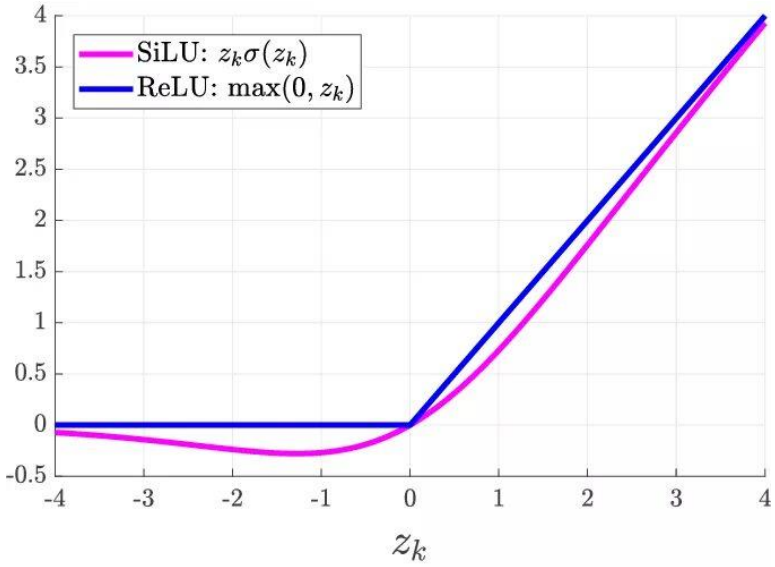
Vanilla: обучение по табличным данным

Настройки обучения
- Оптимизатор: AdamW
- Начальная скорость: lr = 10^{-3}
- Размер батча: 8192
- Снижение скорости: ReduceLROnPlateau
- Ранняя остановка: early stopping

Функция потерь
- Взвешенная MSE
- Без физических штрафов

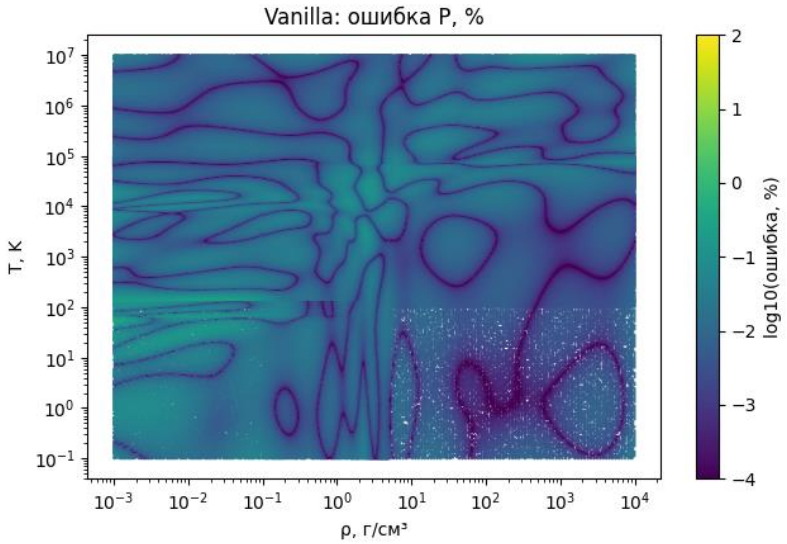
Результат обучения
- До 300 эпох, ранняя остановка
- Медиана ошибки P на test: 1,03%

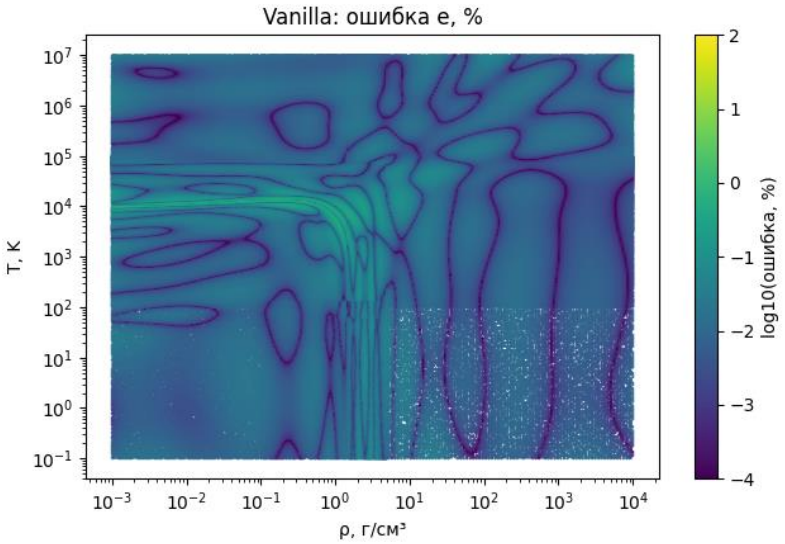
SiLU:



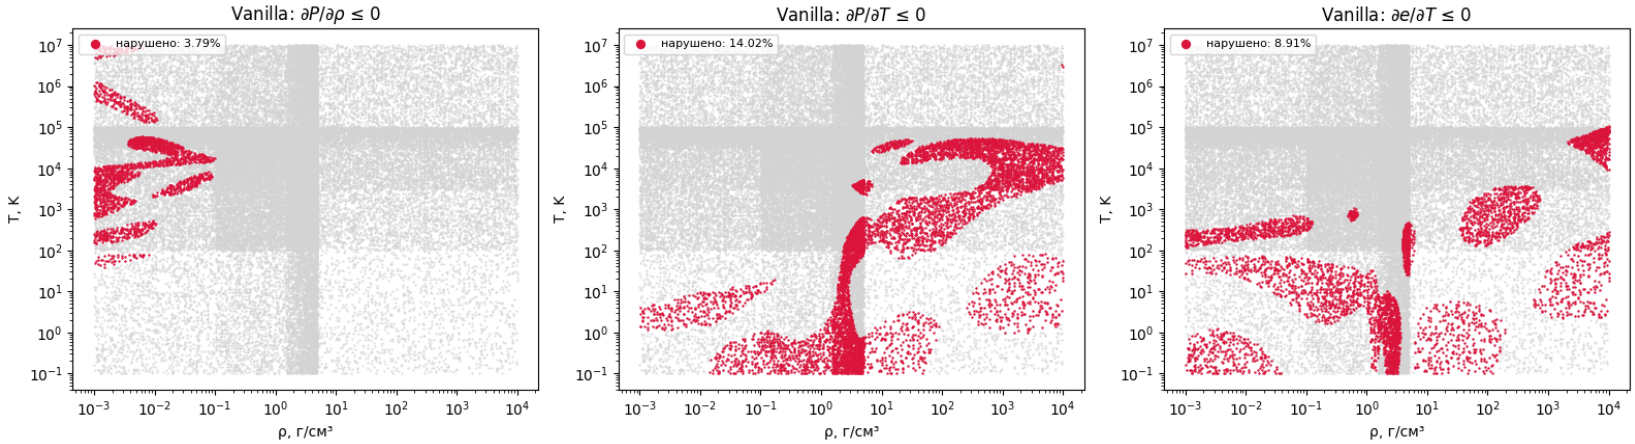
198 658 параметров

Vanilla: карта ошибок на test





Vanilla: где нарушаются условия



PINN: функция потерь

$$L = MSE_{данные} + \lambda_\rho L_\rho + \lambda_T L_T + \lambda_c L_c$$

L_ρ: механическая устойчивость

Штраф mean max(0, $-\partial \ln P / \partial \ln \rho$). Требует $(\partial P/\partial \rho)_T > 0$: давление растёт при сжатии.

L_T: термическая устойчивость

Штраф mean max(0, $-\partial e/\partial \ln T$) / ($|e| + 1$). Требует $(\partial e/\partial T)_\rho \geq 0$; в таблице при $T \lesssim 7$ K плато.

L_c: скорость звука

Штраф за нарушение $0 < c_s < c$, где c — скорость света (п. 3.3 задания).

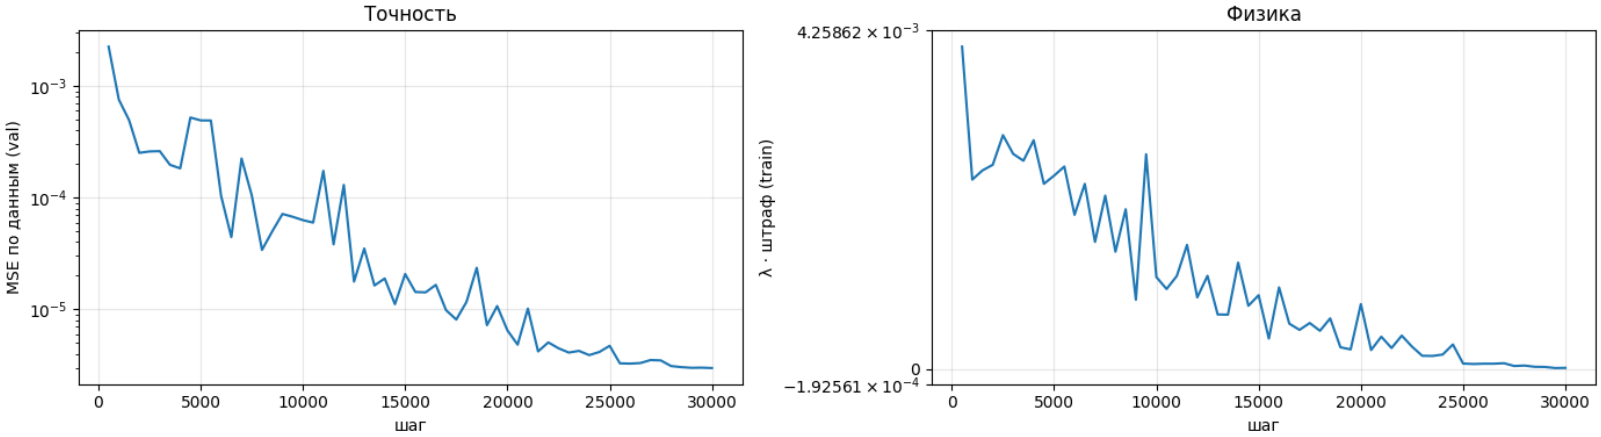
Производные считаются через autograd по ln ρ и ln T, штрафы безразмерные. Они вычисляются в 1024 случайных точках коллокации по всему домену на каждом шаге.

PINN: обучение и согласованность

Настройки обучения

- Сеть 2 → 4×256 → 2, GELU: гладкая активация, потому что производные сети входят в loss
- 30 000 шагов, батч 8192, lr = $2 \cdot 10^{-3}$
- 1024 точки коллокации на шаг
- $\lambda_\rho = \lambda_T = \lambda_c = 1$, веса плавно растут первые 20% шагов
- Старт с той же нормировки и разбиения, что у Vanilla

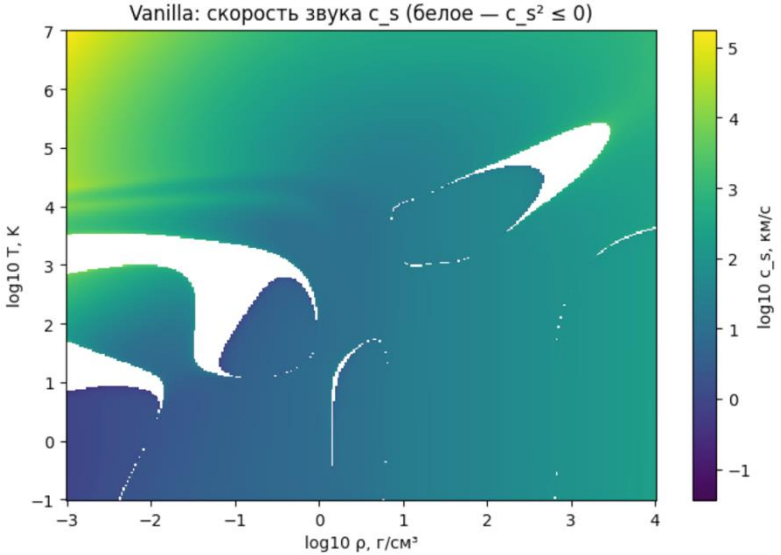
PINN: динамика обучения

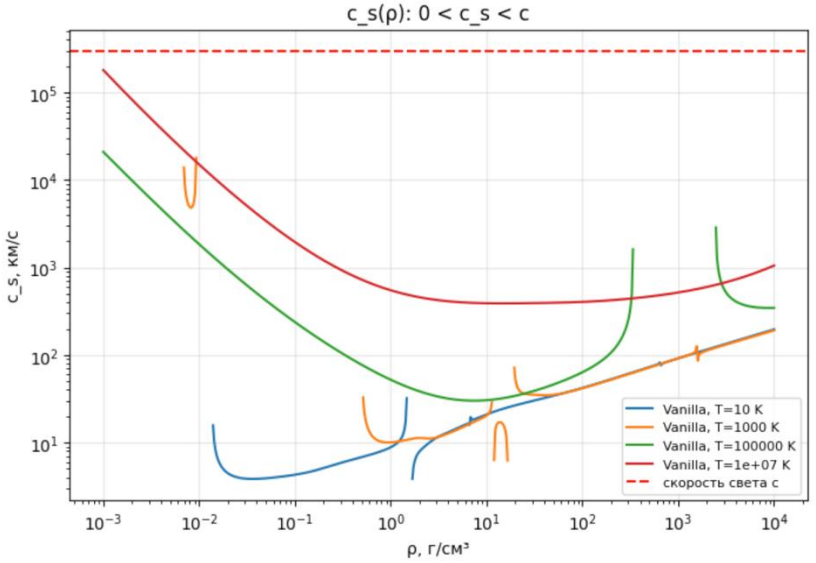


30 000 шагов · 5,5 мин · лучший val MSE = $2{,}973 \cdot 10^{-6}$

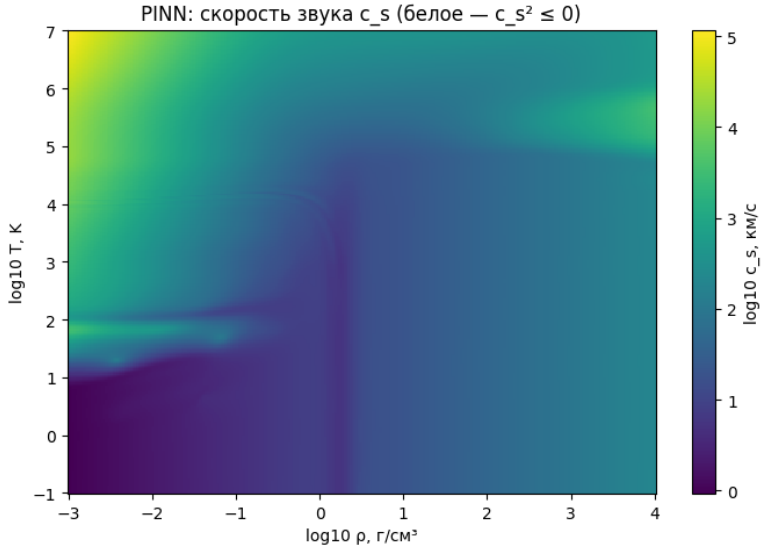
Слева - ошибка на validation, справа - взвешенный физический штраф. Для обоих графиков используются нелинейные шкалы.

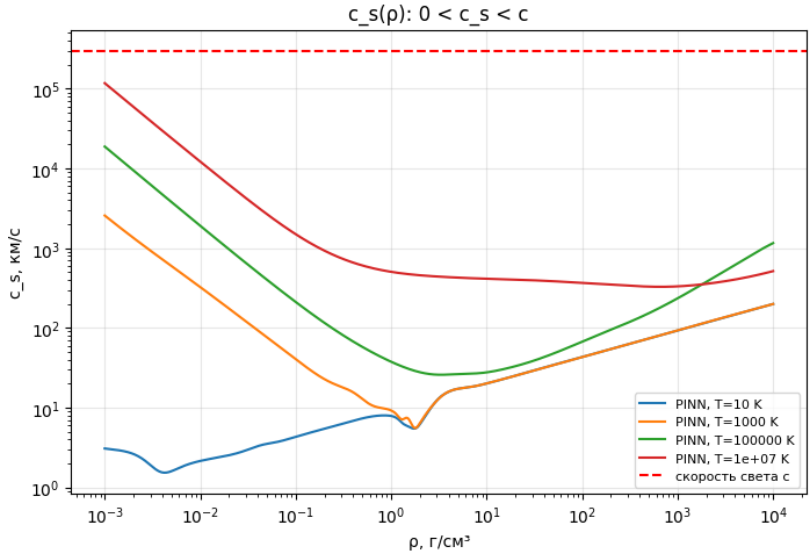
PINN: карта и сечения скорости звука без учета свойств термодинамики





PINN: карта и сечения скорости звука с учетом свойств термодинамики





100 000 случайных точек домена: нарушений $0 < c_s < c$ у PINN - 0%, у полной таблицы через baseline - 4,391%.

Сжатие и скорость работы

float16

0,383 МБ

Вдвое меньше файл, точность та же: медиана ошибки P 0,231% против 0,226%, нарушений нет.

int8, только веса

0,198 МБ

Веса int8 с масштабами по слоям. Файл меньше в 3,9 раза; медиана ошибки P - 1,276%, E - 4,285%.

int8 динамическая

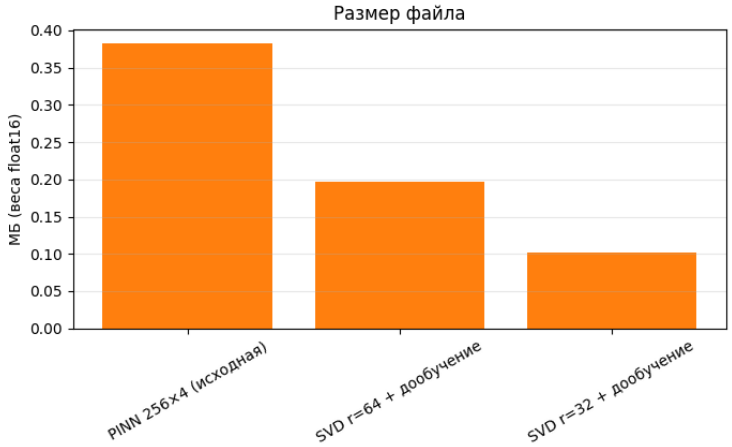
CPU

Квантуются и веса, и активации. В блокноте признана непригодной по точности и не сохраняется.

float16 и int8 измерены на общем test. Итоговым сжатым вариантом выбрана модель float16.

SVD: сжатие с дообучением

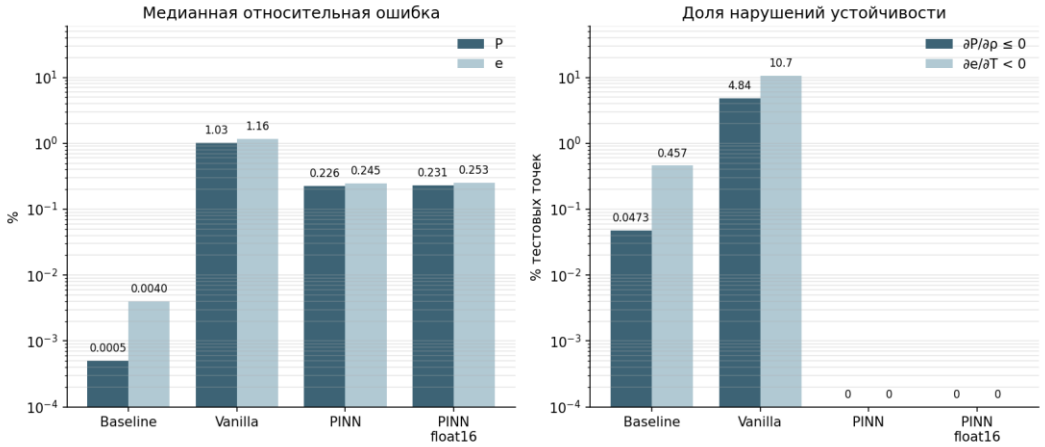




SVD требует дообучения с физическими штрафами

r = 64, 1000 шагов (~17 с): P/E - 0,33% / 0,40%; нарушений - 0%.
Файл: 0,20 МиБ (×2 меньше); CPU ONNX: 0,40 с на 10^5 запросов (×1,3 быстрее).
r = 32: 0,10 МиБ; P/E - 0,43% / 0,50%; сохраняются редкие нарушения.

PINN: результаты на тестовой выборке



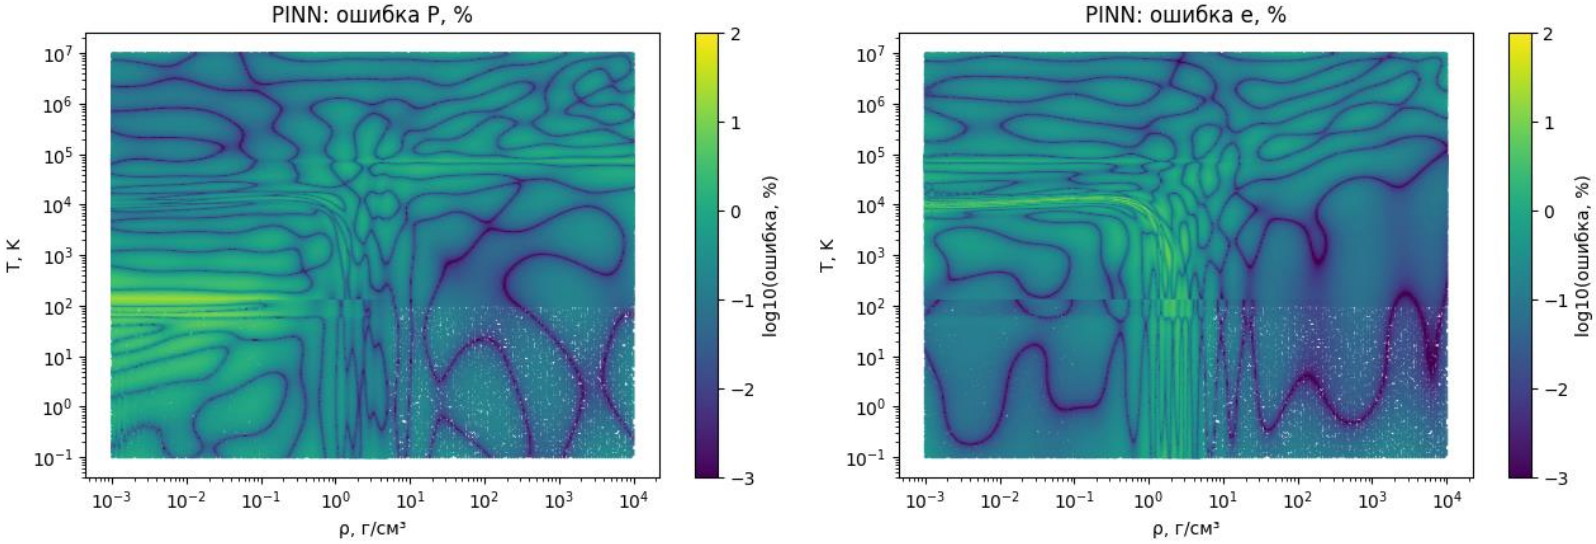
Шкалы логарифмические; у PINN нарушений нет, поэтому столбцы нулевые.

0,23%
медиана ошибки P (у Vanilla 1,03%)

0%
нарушений устойчивости (у Vanilla 4,8% и 10,7%)

0,38 МБ
размер в float16 — в 90 раз меньше таблицы

PINN: распределение ошибок по домену



Общий test: медиана ошибки P = 0,2263%, E = 0,2454%. Максимумы — 21,67% и 19,71%; малая медиана не исключает локальных ошибок.

C - оптимизация

модель	PINN 256×4	PINN SVD r=64
файл весов C, МБ	0.75798	0.38303
макс. отличие P от PyTorch	0.00001	0.00001
ошибка P на test, медиана %	0.22628	0.34150
ошибка e на test, медиана %	0.24539	0.45727
10^5 запросов: PyTorch CPU, с	0.74643	0.65310
10^5 запросов: ONNX Runtime, с	0.55166	0.40040
10^5 запросов: C (из Python), с	1.53804	1.00129
10^5 запросов: чистый C, с	1.61200	0.98600
1 запрос: PyTorch, мкс	684.01757	628.52435
1 запрос: ONNX Runtime, мкс	98.81140	78.45600
1 запрос: C (из Python), мкс	41.97806	21.85355
1 запрос: чистый C, мкс	34.19000	17.07000

C - оптимизация

модель	PINN 256×4	PINN SVD r=64
файл весов C, МБ	0.75798	0.38303
макс. отличие P от PyTorch	0.00001	0.00001
ошибка P на test, медиана %	0.22628	0.34150
ошибка e на test, медиана %	0.24539	0.45727
10^5 запросов: PyTorch CPU, с	0.74643	0.65310
10^5 запросов: ONNX Runtime, с	0.55166	0.40040
10^5 запросов: C (из Python), с	1.53804	1.00129
10^5 запросов: чистый C, с	1.61200	0.98600
1 запрос: PyTorch, мкс	684.01757	628.52435
1 запрос: ONNX Runtime, мкс	98.81140	78.45600
1 запрос: C (из Python), мкс	41.97806	21.85355
1 запрос: чистый C, мкс	34.19000	17.07000

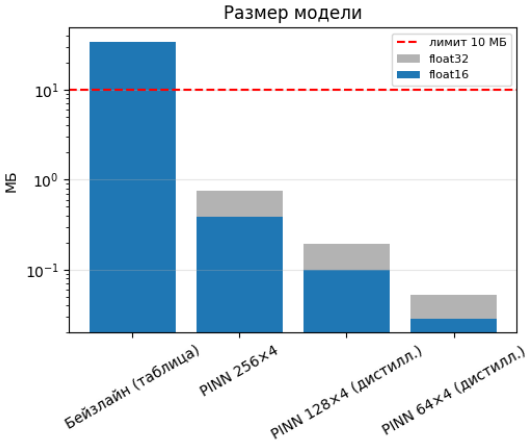
PINN 256×4: один запрос - чистый C 34.2 мкс против PyTorch 684 мкс (×20) и ONNX 99 мкс (×2.9); точность совпадает с PyTorch до 5e-06

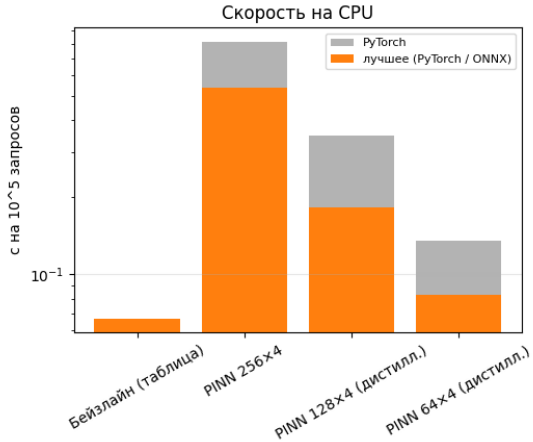
PINN SVD r=64: один запрос - чистый C 17.1 мкс против PyTorch 629 мкс (×37) и ONNX 78 мкс (×4.6); точность совпадает с PyTorch до 8e-06

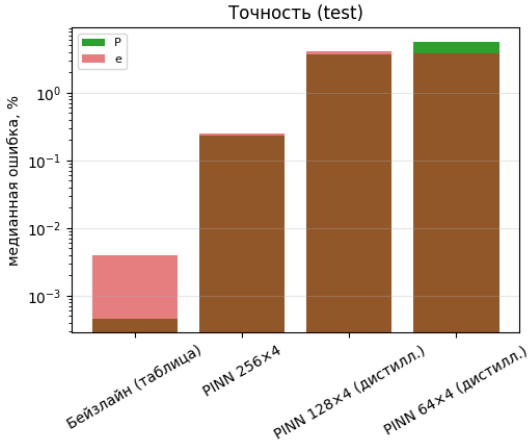
Сравнение моделей

Метрика	Baseline	Vanilla	PINN	PINN float16	SVD	C-оптимизация
Медиана ошибки P, %	0,0005	1,026	0,226	0,231	0,333	0,226
99-й перцентиль P, %	0,0443	9,800	2,591	2,589	2,533	-
Медиана ошибки E, %	0,0040	1,158	0,245	0,253	0,399	0,245
99-й перцентиль E, %	0,1683	27,84	3,168	3,158	3,381	-
Нарушения $\partial P/\partial \rho \le 0$, %	0,0473	4,841	0	0	0	-
Нарушения $\partial E/\partial T < 0$, %	0,4572	10,69	0	0	0	-
Размер, МБ	34,49	0,762	0,762	0,383	0,196	0,758
Время 10^5 запросов, GPU, с	-	0,0234	0,0225	0,0225	0,0162	-
Время 10^5 запросов, CPU, с	0,0667	-	0,776	0,776	0,738	1,612

Оптимизация: размер, CPU и точность











Выводы

Baseline

Точнее всех: медиана ошибки P 0,0005%. Но хранит всю таблицу (34,5 МБ), а производные разрывны на границах ячеек.

Vanilla

0,76 МБ и в 3 раза быстрее baseline на GPU, но точность 1,03% по P и нарушения устойчивости в 4,8% и 10,7% точек.

PINN

Медиана ошибки P 0,23%, E 0,25%; нарушений устойчивости нет. В float16 - 0,38 МБ без потери точности.

Главная находка. Исходная таблица сама нарушает согласованность (отношение ≈ 0,5) и содержит скачок при T ≈ 142 K. Это ограничивает точность любой гладкой модели и определило выбор штрафов PINN.

Репозиторий решения

github.com/Antibote/pinn-eos-aluminum



Спасибо за внимание!